五一数学建模竞赛

承　诺　书

我们仔细阅读了五一数学建模竞赛的竞赛规则。

我们完全明白，在竞赛开始后参赛队员不能以任何方式（包括电话、电子邮件、网上咨询等）与本队以外的任何人（包括指导教师）研究、讨论与赛题有关的问题。

我们知道，抄袭别人的成果是违反竞赛规则的，如果引用别人的成果或其它公开的资料（包括网上查到的资料），必须按照规定的参考文献的表述方式在正文引用处和参考文献中明确列出。

我们郑重承诺，严格遵守竞赛规则，以保证竞赛的公正、公平性。如有违反竞赛规则的行为，我们愿意承担由此引起的一切后果。

我们授权五一数学建模竞赛组委会，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

参赛题号（从 A/B/C 中选择一项填写）：C

参赛队号：T3836517367668

参赛组别（研究生、本科、专科、高中）：本科

所属学校（学校全称）：南京审计大学

参赛队员：　队员 1 姓名：李思齐

队员 2 姓名：夏侯妍妍

队员 3 姓名：徐春飞

联系方式：　Email：18652911295@163.com 联系电话：18652911295

日期：　2024 年 5 月 3 日

（除本页外不允许出现学校及个人信息）

五 一 数 学 建 模 竞 赛

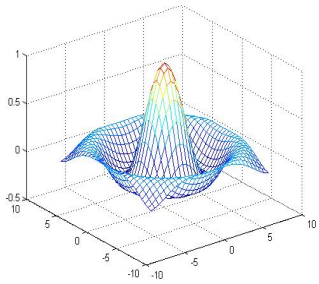

基于统计域和频域的时序信号特征提取与分类判别

摘　要：煤矿深部开采时冲击地压危险的发生可以通过**声发射(AE)信号**和**电磁辐射(EMR)信号**数据进行预测，通过信号数据的变化趋势可以判断目前或未来是否存在冲击地压危险。本文基于统计域、频域和趋势特征对时序信号进行特征提取、分类判别和概率预测。

针对问题一：首先确定需要研究的**统计域与频域**的特征方向，进而分别计算EMR和AE的干扰信号和正常信号数据的特征值，通过干扰信号与正常信号数据在各个特征上的**差异度大小**进行排序，得到差异度最大的三个特征依次为：**声波强度方差、小波方差和持续时间分布频率**（EMR和AE相同）。基于这三个干扰信号的主特征，经检验后，建立**分类判别模型**，利用附件二中的数据对题目指定时间段的干扰信号所在的时间区间进行识别，得出结果见表3和表4。

针对问题二：首先确定需要研究的**谱域和趋势特征**，然后分别对附件一中EMR和AE的前兆信号和正常信号数据进行该方向的各个趋势特征的建模计算，通过前兆信号与正常信号数据在各个特征上的**差异度大小**进行排序，确定差异度最大的前三个特征：**循环动态最大值，序列趋势变化和小波方差**（EMR和AE相同）。基于这三个前兆信号的主特征，建立**随机森林分类预测模型**，将附件1中的所有B类信号数据作为原始训练集构建**三棵决策树**，将训练后的决策树用于题目中指定时间区间内的EMR和AE的前兆信号识别判断，分别取前五个得出结果见表6和表7。

针对问题三：通过假定**理想前兆信号**和**理想非前兆信号**，基于问题二中分析出的前兆信号的三大主特征，建立**基于时间序列预测的相似度判别模型**，融合插值法、**ARIMA时间序列模型**、**距离-相似度转换模型**，用于预测指定的时间段末能够出现前兆信号的概率，分别代入附件三中ERM和AE的五个时间段数据，得到的概率见表9。

通过上述问题的解决，可以通过采集声发射(AE)信号和电磁辐射(EMR)信号数据实现煤矿深部开采冲击地压的监测预警，及时对风险作出应对，保障煤炭的安全高效开采。

关键词：信号特征提取，小波分析，随机森林分类，ARIMA时间序列

一．问题重述

采矿是人们使用煤炭资源的基本方式，但随着开采深度和面积的不断扩大，地应力也在显著增强。此过程产生的冲击地压威胁是影响我国煤矿生产的首要因素。为了更好地预测采矿危机，两种有效的措施是监测声发射(AE)和电磁辐射(EMR)信号。题目将监测声发射信号和电磁辐射信号分为五大类别，我们将针对上述分类解决以下几个问题：

（1.1）附件 1 给出了五大类信号从 2019 年到 2020 年的监测结果，C 类干扰信号的部分数据特征将基于对附件的分析得出。

（1.2）附件 2 给出了 2022 年两个时间段声发射信号和电磁辐射信号的监测时间和数据。本题将以问题一中得出的数据特征为参考，识别所给数据中属于 C 类干扰信号的时间区间，并给出前五个干扰信号出现的具体时间段。

（2.1）本题要求分别对电磁辐射信号（EMR）和声发射信号（AE）的前兆数据（B 类数据）的进行趋势特征分析，得到该类信号的数个比较明显的趋势特征值。与第一问的区别是新增了两种信号随时间循环增大的条件。

（2.2）本题需要基于前文所得和前兆特征信号相关的趋势特征建立数学模型，对给定时间段中的信号值分别进行识别，并找出前五个发生前兆特征的估计时间区间。

（3）为了尽早地识别出前兆数据来对将要产生的危害及时进行应对，题中给出来数个不连续的时间段，要求根据目标时间点之前所采集的信号数据进行分析，建立模型，判断出在各个时间段的最后时刻出现前兆特征的概率。

二．问题分析

1.1 干扰信号特征分析

通过分析附件一中的数据，正常信号和干扰信号在时间分布上具有显著特征[1]，A 类主要集中于夜间其他工作不进行的阶段，而 C 类主要聚集于白天各部门正常工作阶段。由于煤矿附近的其他生产生活也在同期进行，导致监测声发射信号和电磁辐射信号受到干扰。在概率统计领域，数据特征主要体现为基本统计量，统计域中的基本统计量信息可以更好地对干扰信号进行研究分析。通过查阅相关资料，信号的谱域特征也是一类可以显著反映信号类别的研究对象。在《地震高频信号的频谱特征及其在薄层分频解释中的应用》[2]一文中，作者提到了地震资料中包含较宽的频段范围和较高的高截频率,分频解释方法可有效挖掘地震高频信息并提高薄储层预测精度。频谱分析能极大地获取信号中包含的信息，谱域分析将有效提高结果的准确性。本题将首先计算多种特征所占的权重，按权重从高到低的顺序对主特征进行排序，接着针对附件 2 给出的两个时间段内的监测结果进行对比。

1.2 监测结果的干扰判别

在上一问的解答过程中，我们已经得出了干扰信号的三个主特征是：统计方差、小波方差和持续时间分布频率。在本问中，我们将以此作为参考依据，基于特征归一化后的欧几里得距离对附件 2 中的待检测信号进行二分类，达到区间识别的效果。进而给出前五个干扰信号出现的时间区间。

2.1 前兆信号趋势特征分析

本题研究前兆特征信号的趋势特征，除了沿用问题 1 中的相关数据特征外，本题还需要加入移动平均特征值，主要包括谱域特征，滑动平均值，周期性特征等。其中谱域特征采用傅里叶变换平均系数、小波绝对均值[3]、小波标准差、小波方差

为代表进行分析计算。由于 B 类数据具有波动上升的趋势，采用 SARIMA 差分时间序列对 B 类数据进行建模[4]，采用逐步增加法计算信号周期和滑动平均值[5]。

对 EMR 和 AE 中的正常 A 类数据以及 B 类数据进行这三类数据特征的计算求解，然后计算 B 类数据与正常 A 类数据的差异度，进行排序选取前三个作为 B 类前兆数据的主要趋势特征。

2.2 前兆信号的分类判别

前兆特征信号是对冲击地压危险的一种反向预测，随着前兆信号强度的不断增大，冲击地压发生时刻将越来越近。本题将使用随机森林分类预测模型[6]，依据循环动态最大值、信号的滑动平均值和一阶差分序列的小波方差三个趋势特征对附件中的数据进行前兆信号识别，规定前兆信号为 1，其余非前兆信号为 0。考虑到前兆特征信号具有循环增大的特点，因此动态最大值法的匹配结果将作为参考依据进行辅助判别。

3 前兆信号出现概率

为了尽早地识别出前兆数据来对将要产生的危害及时进行应对，题中给出来数个不连续的时间段，要求根据目标时间点之前所采集的信号数据进行分析，建立模型，判断出在各个时间段的最后时刻出现前兆特征的概率。

三．模型假设

1. 假设已确定的 A、B、C 类信号数据真实且 C 类是完全干扰信号，B 类是完全前兆信号。

2. C 类信号主要研究数据特征，B 类数据的主要特征完全为趋势特征，两类信号的其它任何非趋势特征与 A 类数据一致。

3. 用差异度的概念来模拟 C、B 类数据与 A 类数据的特征的差异程度，差异程度越大可以认为 C、B 类数据的特征性越强，越能代表两类数据的主要特征。

4. 在判断 B、C 类信号类型时只判断属于或不属于该类别。

四．符号说明

变量	名称	单位
r	自相关系数	/
x	信号值	/
ffl	傅里叶变换平均系数	/
$\overline{wam}$	小波绝对均值	/
wsd	小波标准差	/
wv	小波方差	/
λ	差异度	/
h，g	小波变换滤波器系数	/
dwt	重构小波信号	/
L	特征的笛卡尔距离	/
F	特征向量	/
α	相似度	/
δ	置信度	/
β	发生预兆信号的概率	/

五．模型的建立与求解

数据预处理：

（1）附件中存在大量的重复值，由于数据总量庞大，对于重复时间的数据取均值。

（2）本题中所有延续时间较短的信号由于出现的频率极低，在讨论中忽略不计。

（3）本题按照信号类别进行划分，由于不同类别数据的时间段分散在 24 小时中，因此将不同时间段的同一信号作整体考虑。

（4）将时间数据进行标准化，附件中的所有时间都转换为时间戳。

（5）规定映射函数 $f(x)=\begin{cases} A\to 1 \\ B\to 2 \\ C\to 3 \\ D/E\to 4 \end{cases}$

5.1 干扰信号特征分析与预测

5.1.1 干扰信号特征判别模型

（1）模型建立

由于同为干扰数据的存在时间段并非连续，因此需要对同为干扰信号的前后时段进行自相关分析：

$$r=\sum_{i=1}^{n-h}\frac{(x_i-\mu)(x_{i+h}-\mu)}{\sum_{i=1}^{n}(x_i-\mu)^2}$$

干扰信号前后出现的波动都将成为信号不正常的因素，在一个干扰信号周围的信号特征相似度将较高，因此认为干扰数据存在较大的自相关性。

本题将选取时间分布、统计域、谱域三种特征建立干扰信号判别模型。首先以 A 类数据为标准，将 C 类数据的对应特征和 A 类数据进行差异度检验，选取前三位作为主特征进行分析。

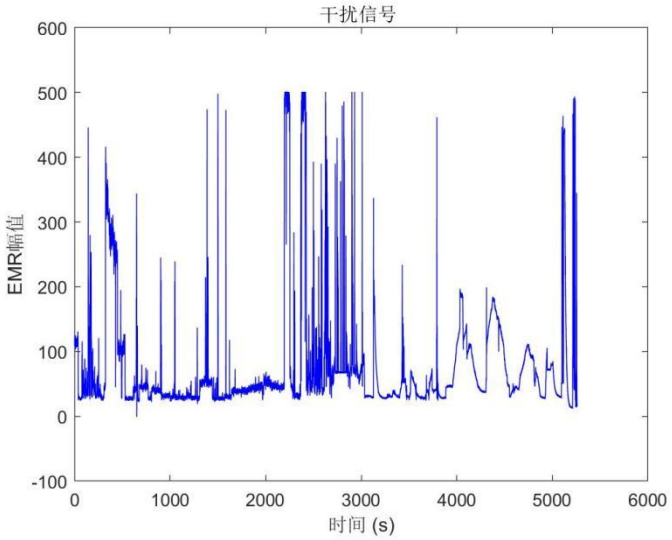

图 1 干扰信号 EMR 信号图像

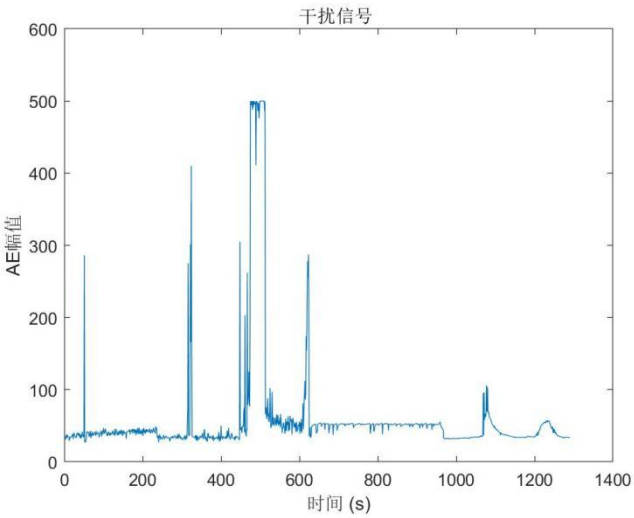

图 2 干扰信号幅值图像

1）时序特征：在日间干扰信号强度较大，且通过分析所给数据得到干扰信号的平均持续时间约为 1.7 小时。

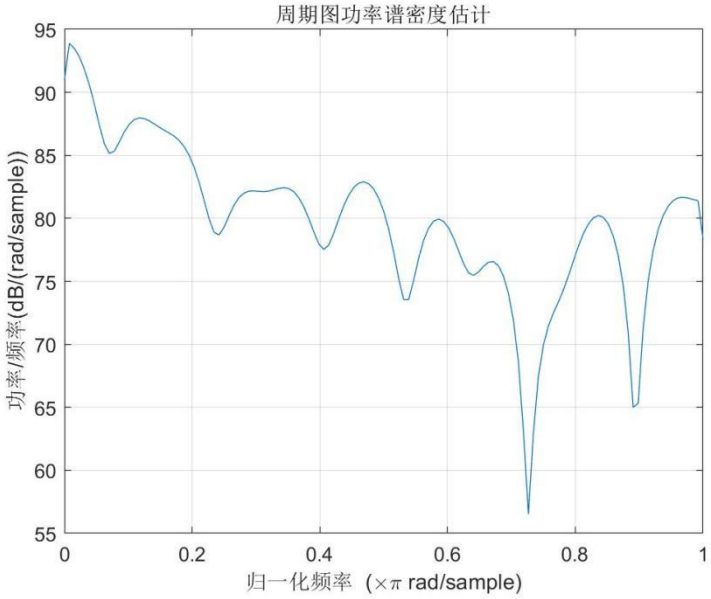

图 3 周期图功率谱密度估计

2）统计域特征：A 和 C 类信号基本统计量通常体现为期望、方差等等，此处列出较为常见的基本统计量算式。

期望：

$$X_{n+1}^{t}=\frac{\sum_{i=1}^{n}X_{\mathrm{i}}}{n}=\frac{X_1+X_2+\ldots+X_n}{n}$$

方差：

$$\sigma^2=\frac{\sum_{i=1}^{N}(x_i-\overline{x})^2}{N}$$

其中 x_i 指附件 1 中所有 A、C 类干扰数据。
偏度：

$$S_{\mathrm{k}}=\frac{\mu_3}{\mu_2^{3/2}}=\frac{\mu^3}{\sigma^3}$$

其中 S_k 为干扰数据偏度； μ_3 为 3 阶中心矩;σ为标准差。
中位数：

$$M_{\mathrm{e}}=\begin{cases}x_{n/2+1}（n为奇数）\\ \dfrac{x_{n/2}+x_{n/2-1}}{2}（n为偶数）\end{cases}$$

3）谱域特征：通过求出干扰数据的傅里叶系数和小波系数进行频谱分析得出相关特征。快速离散傅里叶变换 *DFT* 如下所示，将下式所得结果进行平方即可得到能量谱特征信息。

$$x_k=\sum_{i=0}^{n-1}x_i e^{-i2\pi ki/n}$$

一维离散小波变换 *DWT*：

$$\begin{cases}c_{i,j}=\sum_n h_{j,k}(i)x_i\\ d_{i,j}=\sum_n g_{j,k}(i)x_i\end{cases}$$

$$dwt_{j,k}=c_{j,k}+d_{i,j}$$

傅里叶变换平均系数 *ffl*:

$$ffl=\overline{x_k}=\frac{1}{n}\sum x_k$$

小波绝对均值 $\overline{wam}$：

$$\overline{wam}=\frac{1}{n}\sum_n\left|dwt_{j,k}\right|$$

小波方差 *wv*：

$$\overline{dwt}=\frac{1}{n}\sum_n dwt_{j,k}$$

$$wv=\frac{1}{n}\sum_n(dwt_i-\overline{dwt})^2$$

小波标准差 wsd：

$$wsd=\sqrt{wv}$$

进而对 A 类、C 类数据进行差异度检验。

$$\sigma = \left| \frac{F_C - F_A}{F_A} \right| \times 100\%$$

取差异度较小的前三个特征作为主特征。

（2）模型求解

表 1 声发射、电磁辐射干扰信号与正常信号的的谱域特征差异

谱域特征	声发射信号差异	电磁辐射信号差异
小波绝对均值	0.60	0.57
傅里叶变换平均系数	4.77	1.27
小波标准差	20.63	3.86
小波方差	466.74	22.60

根据上表分析可得，干扰信号的小波方差特征最为显著。

表 2 声发射、电磁辐射干扰信号与正常信号统计域特征差异

统计域特征	声发射信号差异	电磁辐射差异
最大值	5.26	0.85
最小值	0.07	1.00
标准差	20.55	3.96
方差	463.43	23.62
中位数	4.89	0.03
四分位距	4.8	3.58
绝对误差均值	0.6	4.28
均方根	1.67	1.25
偏度	0.92	0.19
峰度	0.95	0.52

根据上表分析，在统计域中方差最为显著。

最终确认的干扰数据特征为：统计方差、小波方差和持续时间分布频率。

（3）模型评价

本模型基于数理统计分析，基本统计量能精确反映出信号的统计域特征；自相关分析中找到了时间不重叠的信号之间的相互关联，让结果更具可靠性，但同时理想化部分数据，且对其他数据特征未做相关分析，不排除对结果存在其他影响。

5.1.2 基于特征归一化的欧氏距离二分类模型

（1）模型建立

由附件 1 可知，题目给出的 C 类干扰信号时间段长短不一。为了系统性地分析干扰信号的数据特征并精准判别产生干扰信号的时间区间。首先使用对附件 1 中所有 C 类信号进行时间长度计算，判断出连续监测时间最短的干扰信号时长；接着在对每一段干扰信号进行分析时，从开始时间点取最短时间进行分析。另外，三大数据特征的量纲存在差异，为防止量纲对分析产生影响，本题我们将进行如下特征归一化和标准化处理，将三大特征数据映射在区间[0,1]中。规定检测结果在 C 类估计值之内的干扰数据的记为 1，非 C 类数据记为 0。

由于电磁辐射和声发射监测每半分钟进行一次，数据较为密集。此处使用离差

标准化方法：

$$x_{new} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

其中 *max* 为样本数据的最大值，*min* 为样本数据的最小值。
再计算附件 2 中待监测信号和参考信号间频率的欧几里得距离：

$$l = \sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

其中所有样本 x_i 均来自附件 2 中的监测数据，参考值为干扰信号的三大特征。
在不断迭代检测过程中，距离和相似度将不断上下浮变化，本题取极大值为 C 类数据出现时刻。

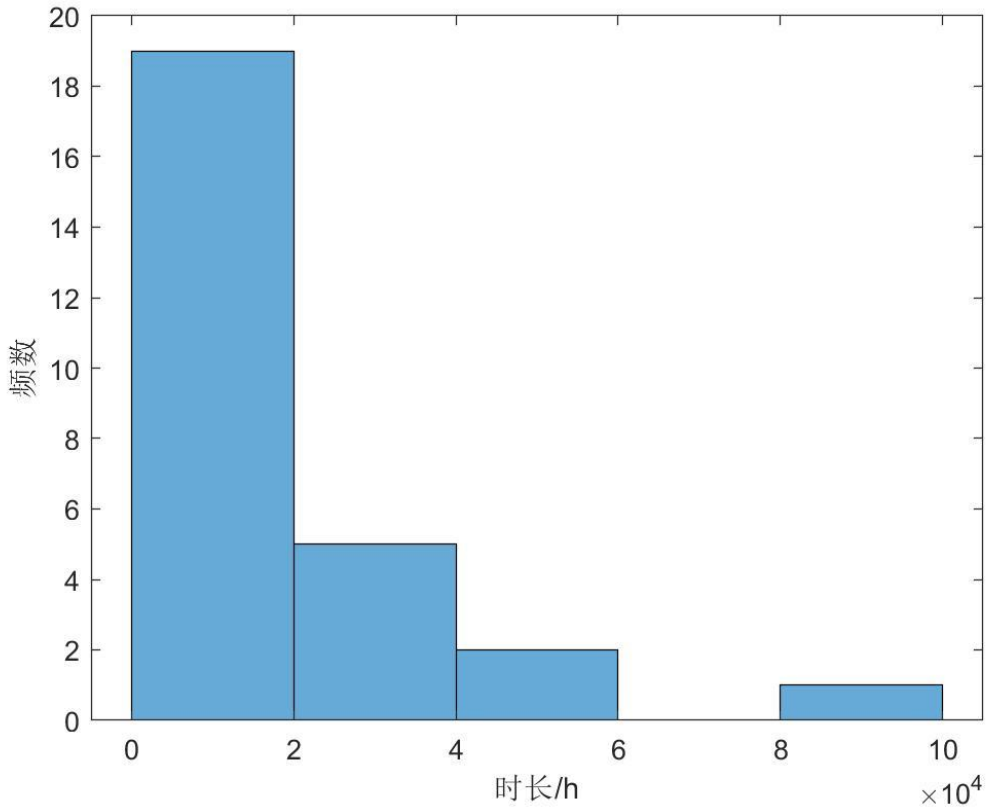

图 4 时长频数统计

当距离最小时，可认为被检测数据一定在 C 类干扰数据区间内，前五个最小值出现的时间区间即为所求。

（2）模型求解

最终得到的结果如下：

表 3 电磁辐射干扰信号时间区间

序号	时间区间起点	时间区间终点
1	2022/5/4 20:01:26	2022/5/4 21:29:47
2	2022/5/14 06:41:47	2022/5/14 09:12:08
3	2022/5/14 10:21:16	2022/5/14 12:22:38
4	2022/5/15 18:37:08	2022/5/15 20:20:29
5	2022/5/16 06:26:45	2022/5/16 06:58:07

表 4 声发射干扰信号时间区间

序号	时间区间起点	时间区间终点
1	2022/4/2 12:46:00	2022/4/2 13:16:21
2	2022/4/2 23:51:42	2022/4/3 00:40:03
3	2022/4/3 01:34:07	2022/4/3 02:04:27
4	2022/4/9 19:02:14	2022/4/9 19:37:35
5	2022/4/24 09:15:37	2022/4/24 11::58

（3）模型评价：

本模型使用了经欧氏距离优化后的二分类模型，在原有的二分类模型上更能反映出待检测数据和参考干扰数据之间的差异和关联，但相较于决策树本模型在其他影响因素方面考虑并不详细。

5.2 前兆特征信号特征分析与预测

5.2.1 前兆信号趋势特征判别模型

（1）模型建立

自相关分析：

考虑到信号的类别是由该时刻的客观事实（数天是否发生冲击地压的危险）决定，但是主观上并不能直接对该信号的分析判断其是否为前兆信号，因此可以认为，在对某一时刻的信号进行研究时，对其所属类别的判断并非直接该时刻的信号的值，而是由该时刻前后信号的整体趋势共同决定，因此考虑一个信号与其自身在不同时间点的互相关关系，应当对 B 类信号进行自相关分析。

趋势特征向量 F：

$$F=[ffl,wam,wsd,wv,MA,MMAX_i,T,x_i']$$

Mann-kendall 突变点检验：

$$构造秩序列：S_k=\sum_{i=1}^{k}\sum_{j}^{i-1}a_{ij},k=2,3,\ldots,n$$

$$a_{ij}=\begin{cases}1,x_i>x_j,1\le i\le j\\0,x_i\le x_j,1\le i\le j\end{cases}$$

定义统计量：

$$UF_k=\frac{S_k-E(S_k)}{\sqrt{Var(S_k)}},k=1,2,\ldots,n$$

$$E(S_k)=\frac{k(k+1)}{4}$$

$$Var(S_k)=\frac{k(k-1)(2k+5)}{72}$$

若$|UF_k|>U_a$，可以认为序列有显著的趋势变化。

滑动平均值 MA：

$$\mathrm{MA}(i)=\frac{1}{i}\sum_{z=1}^{i}x_z,i=1,2,3\cdots\cdots$$

建立循环动态最大值：

循环动态最大值法是指从设定的第一个值开始,不断向后取最大值，一直取到设定的最后一个值。MMAX 用于记录从起始记录点到当前位置的最大值，每一个数值都会有一个相对应的 MMAX。

$$MMAX_i=\max\{[x_{start}x_i]\}$$

设定最小容忍阈值η，其表示可以容忍的最大值未上升的持续时间。例如，在 t 时刻$MMax_t=x_t$，但在后面的η时间内，$MMAX$一直不变，并保持x_t。因此认为，在最小可容忍阈值内不存在波动上升的趋势。此时，在第$\eta+1$个时刻，规定

$$x_{start}=x_\eta$$

$$MMAX_\eta=0$$

不断循环，可以得到一个信号的一组$MMax_i$。

考虑周期性 T，从题目分析可知：

$$0<T<7$$

对每一次发生 B 类信号的发生的持续时间长度进行统计，可以得到 B 类信号的单次持续时间的概率分布 *f(T)*，可以发现 *f(T)*近似符合正态分布。

可以发现 T 主要为一天，在 *f(T)*中，利用 3σ 法则，确定一个 $\overline{f(T)}-3\sigma(f(T))$ 期间小于该值的可能性极小，因此将该值视为最小合理阈值，即：

$$\eta=\overline{f(T)}-3\sigma(f(T))$$

建立一阶差分序列模型，得到差分序列 x_i'：

$$x_i'=x_{i+1}-x_i$$

通过上式对差分序列求相应的谱域特征。

构造差异度 λ：

$$\lambda=\left|\frac{F_B\text{-}F_A}{F_A}\right|\times 100\%$$

按照差异度的值进行降序排序，取出 B 类 F 中前三个特征：

$$F_B=F_B[1,2,3]$$

（2）模型求解

根据附件 1 中数据，将数据分为两大类 EMR 和 AE，分别计算。筛选出 A 类数据和 B 类数据，代入上述模型，分别计算得到各个主要的前三趋势特征。

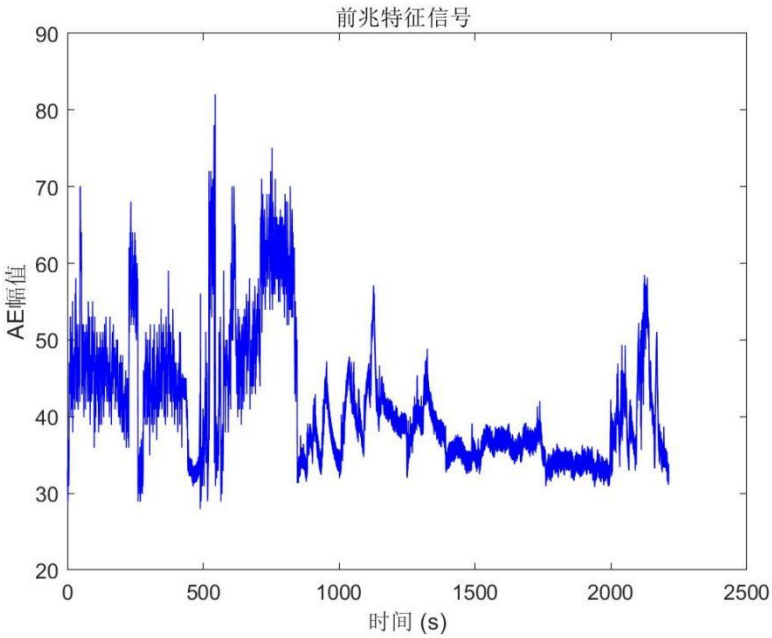

图 5 前兆特征 AE 信号图像

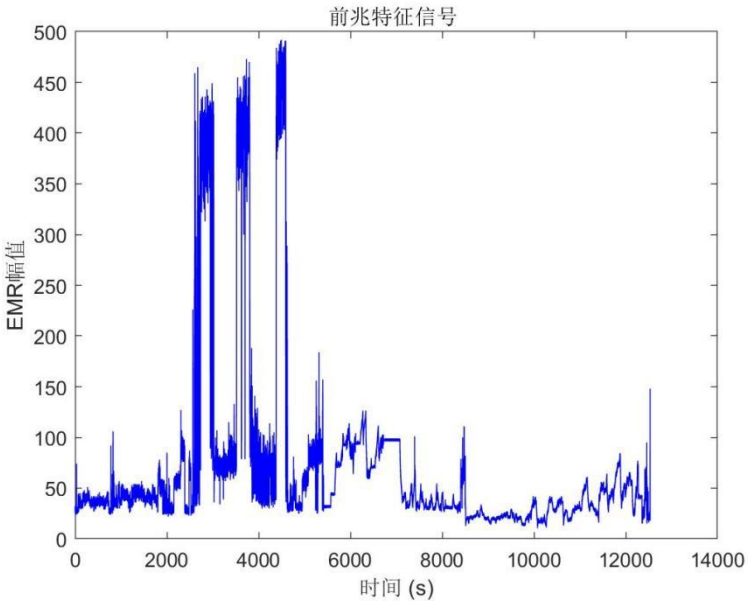

图 6 前兆特征信号 EMR 图像

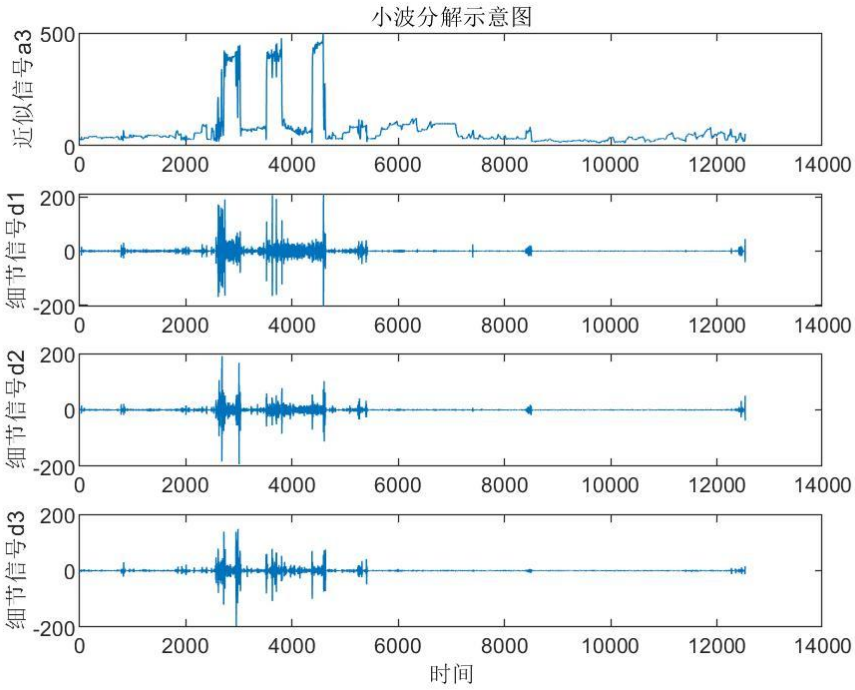

图 7 小波分解示意图

最终得出的三个前兆信号的主特征如下表所示：

表 5 前兆信号主特征

EMR	AE
MMAX 在最小可容忍区间内递增	MMAX 在最小可容忍区间内递增
序列趋势变化大	序列有显著趋势变化
小波方差显著大于正常值	小波方差显著大于正常值

（3）模型评价

特征的选取是通过与正常值进行对比后计算偏差度进行排序后得出，较为科学准确；基于数据进行特征提取，灵敏度较高，较为科学准确；样本量大，可以消除较多随机干扰因素。

5.2.2 前兆信号的随机森林分类预测模型

（1）模型建立

为了更好地匹配检验附件 2 中的所有 B 类数据，本题将在第一问的基础上进行进一步优化，采用随机森林分类预测模型进行求解。

首先对数据进行处理，消除重复值并补齐缺失值；将附件 1 中的所有 B 类信号数据作为原始训练集构建决策树，在原始训练集中算出三个主要特征值，规定判别结果仅有 B 类和非 B 类两种。接着根据三类特征值构建个体学习器 h_i，满足 $h_i(i=1,2,3)$，对附件 2 中的数据进行有放回随机抽样并训练，抽取待检测数据的部分特征进行分析，经过不断匹配，待检测数据将被分配到三棵决策树上，在其中不乏同时存在于三棵决策树上的信号，可以认为这些信号和前兆特征信号的匹配程度最高，三棵决策树会根据匹配结果对加入训练集的新数据进行投票，给出是否属于 B 类前兆特征信号的判别，最终选择票数最多的信号认定为 B 类。

（2）模型求解

对分类预测模型进行评估，可以得到以下结果：

准确率：

$$Accuracy=\frac{TP+TN}{TP+TN+FP+FN}$$

精确率：

$$precision=\frac{TP}{TP+FN}$$

召回率：

$$recall=\frac{TP}{TP+FN}$$

$F_1-score$：

$$F_1-score=\frac{2\times precision\times recall}{precision+recall}$$

其中 TP、TN、FP、FN 分别表示正确预测为 B 类，正确预测为非 B 类，错误预测为 B 类和错误预测为非 B 类四种预测结果。

上述信息可评估结果的准确性。

（2）模型求解

最终得到的结果如下两表所示：

表 6 电磁辐射前兆特征时间区间

序号	时间区间起点	时间区间终点
1	2019/1/27 14:40:28	2019/1/27 15:20:50
2	2019/1/27 15:22:54	2019/1/27 16:03:17
3	2019/1/27 21:26:46	2019/1/28 13:11:10
4	2019/1/28 15:49:33	2019/1/28 16:29:55
5	2019/1/29 17:02:12	2019/1/29 17:42:34

表 7 声发射前兆特征时间区间

序号	时间区间起点	时间区间终点
1	2019/1/9 10:58:57	2019/1/9 11:39:49
2	2019/1/16 21:18:11	2019/1/16 21:58:33
3	2019/1/16 22:04:46	2019/1/16 22:45:08
4	2019/9/8 18:43:19	2019/9/8 19:24:01
5	2019/9/8 19:54:33	2019/9/8 20:35:15

（3）模型评价

由于信号监测的频次较高，数据密集，在结合随机森林方式拟合信号类型过程中具有较好的泛化性能，能有效防止过度拟合。

在进行交叉验证的过程中，数据集和检验集相对独立且尽可能多地作为训练集加入训练，保证结果的有效性。

5.3 前兆特征信号出现概率的 ARIMA 时间序列判别

（1）模型建立

本题对目标数据建立 ARIMA 时间序列预测模型：

$$ARIMA(p,d,q):(1-\Phi 1B-\Phi_2B^2-\cdots-\Phi_pB^p)(1-B)^dX_t=(1+\theta_1B+\theta_2B^2+\cdots+\theta_qB^q)\mathrm{v}_t$$

一个时间段最后时刻 *t'*，其后面采用 ARIMA 模型进行预测其信号值，预测的时间长度为，间隔为 30s，记预测的置信度为δ。

建立距离-相似度转换模型：

对于每一个时间段的最后时刻，采用该时刻的前$\frac{t_0}{2}$时刻至后$\frac{t_0}{2}$时刻作为目标信号，记作$W(F_1,F_2,F_3)$，其中 *F1*，*F2*，*F3* 是和$F_B(F_1,F_2,F_3)$和$F^{\neg}{}_B(F_1,F_2,F_3)$一致的特征分量。

定义特征的欧式距离：

$$L=\sqrt{\sum_{i=1}^{3}(F_{i1}-F_{i2})^2}$$

计算目标信号在特定特征分量上的欧式距离 L：

$$L_1=\sqrt{\sum_{i=1}^{3}(F_{iW}-F_{iF})^2}$$

$$L_2=\sqrt{\sum_{i=1}^{3}(F_{iW}-F_{i\neg F})^2}$$

L1 的意义是目标信号 W 与理想 B 类信号的特征差距，L2 的意义是目标信号与标准非 B 类信号的特征差距。

用距离来模拟与 B 类的相似度，由于假设只存在两类数据，要么是 B 类，要么就是非 B 类，可以认为，距离非 B 类的特征距离占二者总距离的比重就是其与标准 B 类的相似度。因此下面定义某个目标信号与 B 类信号的相似度 α：

$$\alpha=\frac{L_{W\neg F}}{L_{WF}+L_{W\neg F}}\times 100\%$$

那么目标信号在中间时间点（也就是题目中时间段的最后时刻）后会发生预兆信号的概率 β 为：

$$\beta=\alpha\delta$$

（2）模型求解

本题中，首先需要确定理想 B 类信号的三个主要特征，参考题目 2.1 中的三个特征：

表 8 三大主趋势特征

EMR	AE
MMAX 在最小可容忍区间内递增	MMAX 在最小可容忍区间内递增
序列趋势 UF 变化大	序列有显著趋势变化
小波方差 wv 显著大于正常值	小波方差显著大于正常值

确定分别确定理想 B 类和标准非 B 类的三个特征：理想 B 类的特征采用附件一中 B 类训练数据集该特征的平均值，标准非 B 类数据采用附件一中除 B 类以外的其他所有信号的该特征的均值用于估计 $F_B(F_1,F_2,F_3)$ 和 $F_{\neg B}(F_1,F_2,F_3)$。

确定时间 t_0：采用训练数据集中 B 类数据的持续时间的期望值。

基于此，将附件三中的五段 EMR 数据和五段 AE 数据首先进行插值，使得时间间隔在 60s，再代入 ARIMA 模型进行预测，最后选定目标信号，代入模型相似度、概率计算。

最终得到的结果为：

表 9 前兆特征信号出现概率预测

电磁辐射数据所在时刻	前兆特征的概率	声发射数据所在时刻	前兆特征的概率
2023-1-24 23:58:36	92.14%	2023-1-24 23:58:36	12.47%
2023-2-11 23:59:20	67.75%	2023-2-11 23:59:20	45.05%
2023-2-26 23:59:27	14.22%	2023-2-26 23:59:27	65.34%
2023-3-10 23:58:14	12.6%	2023-3-10 23:58:14	7.46%
2023-3-30 23:58:13	15.47%	2023-3-30 23:58:13	89.78%

（3）模型评价：

本模型的假设过于理想化，假设了两个理想化的 B 类和非 B 类信号，在实际的模型求解中采用的是第二问中的大量均值进行估计，存在较大的误差。

本模型采用距离来模拟相似度，相似度来模拟概率，采用古典概型概率和几何概型概率，也考虑了拟合效果的置信度，具有较好的估计概率的效果。

六．灵敏度分析与误差分析

问题一中，建立基于特征归一化的欧氏距离二分类模型，模型的灵敏度，通过分析模型可以发现，该模型首先由于数据密集以及量纲差异进行了离差标准化导致数据处于[0,1]之间，这就使得后续的距离的计算中，一个变量的变动所产生的模型计算结果只能产生小幅度的变动，因此可以分析出该模型的灵敏度较低。

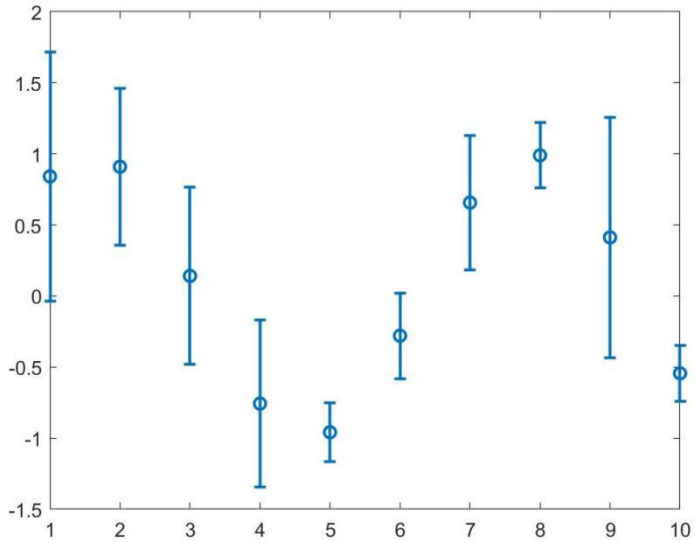

图 8 问题一误差分析

问题二中，建立随机森林分类预测模型，其误差主要来源于两方面，分别为模型在训练集上上的误差以及模型在不同数据集上的表现误差，通过采用 k 折交叉验证法来计算模型在测试集上的平均误差，输出训练后模型在 k=5 准确率分别为(0.85,0.87,0.89,0.90,0.92),平均准确率不足 95%，仍有较大概率出现误差。

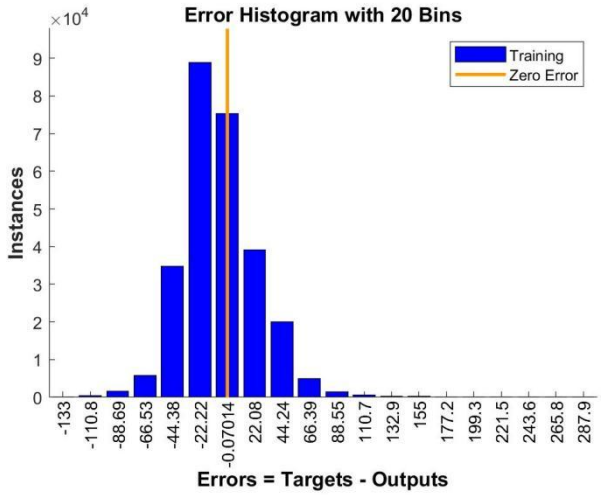

图 9 分类预测误差

问题三中，进行基于时间序列预测的相似度判别模型，由于进行了两个假设，其一是用训练数据的特征均值作为理想值，其二是用 ARIMA 模型进行时间序列的预测，两层假设得出结论会存在较大的误差。该模型由于是基于已有的数据进行插值然后预测，接着计算相似度最后计算概率，不断对数据作用放大，由此可以分析出该模型对于数据的敏感性很高。

七．参考文献

[1]沈月健. 电磁信号对信号分类系统的干扰研究[D].河北科技大学,2024.

[2]齐金成,刘朋坤,杨丽瑛,等.地震高频信号的频谱特征及其在薄层分频解释中的应用[J]//中国石油学会石油物探专业委员会,中国地球物理学会勘探地球物理委员会. 2022 年中国石油物探学术年会论文集（中册）:2022.

[3]覃子宇,韩猛,韩啸,等.基于小波变换的压力脉动信号分析方法[J].北京航空航天大学学报:2024,1-11.

[4]贾旭鹏.MATLAB 在数字信号处理中的应用研究[J].机电信息,2024(05):76-79.

[5]Gao Z ,Wang Y ,Yu K , et al. Cardiac Multi-Frequency Vibration Signal Sensor Module and Feature Extraction Method Based on Vibration Modeling[J]. Sensors, 2024,24(7).

[6]庄小亮,李乾坤,秦秉东,等.基于 MFCC 和随机森林的 GIS 动作声纹特征辨识和操作机构异常分类[J].电机与控制应用,2024,51(03):10-20.

附录

特征提取

```
clear,clc
%%  导入数据
load emr_c.mat
emr_c=emr_c';

%% 三类处理方法
fs_c = 5259; % 采样率
t_c = 0:1/fs_c:1; % 时间向量
f_carrier = 10; % 载波频率
A = 0.05; % 基础信号振幅
% 添加表面缺陷扰动和噪声
defect_amplitude_c = 0.8; % 缺陷振幅
defect_location_c = 0.5; % 缺陷位置
defect_signal_c = zeros(size(t_c));
defect_signal_c(abs(t_c - defect_location_c-0.01)<0.01) = defect_amplitude_c;
defect_signal_c(abs(t_c - defect_location_c+0.01)<0.01) = -defect_amplitude_c;
noise_amplitude =0.1; % 噪声振幅
noise_signal_with_defect_c = noise_amplitude * randn(size(t_c));
% 合并信号（有缺陷）
signal_with_defect_c = emr_c + defect_signal_c + noise_signal_with_defect_c;
% 添加无缺陷的噪声
noise_signal_without_defect_c = noise_amplitude * randn(size(t_c));
% 合并信号（无缺陷）
signal_without_defect_c = emr_c + noise_signal_without_defect_c;
signal_c = signal_with_defect_c;

% 绘制信号图像
figure;
plot(signal_with_defect_c,'b');
title('干扰信号 ');
xlabel('时间 (s)');
ylabel('EMR 幅值');

% 计算基于统计域的时序特征
maximum_value_c = max(signal_c);
minimum_value_c = min(signal_c);
mean_value_c = mean(signal_c);
median_value_c = median(signal_c);
skewness_value_c = skewness(signal_c);
kurtosis_value_c = kurtosis(signal_c);
```

```
histogram_data_c = hist(signal_c, 10); % 计算直方图，分为10个箱子
interquartile_range_c = iqr(signal_c);
mean_absolute_deviation_c = mad(signal_c);
median_absolute_deviation_c = mad(signal_c, 1);
root_mean_square_c = rms(signal_c);
standard_deviation_c = std(signal_c);
variance_c = var(signal_c);
percentile_count_c = prctile(signal_c, [25, 50, 75]); % 计算25、50、75百分位数
ecdf_slope_c = gradient(ecdf(signal_c), range(signal_c)/numel(signal_c)); % 计算经验分布函数斜率

% 计算基于谱域的时序特征
f_signal_c = fft(signal_c); % 计算傅里叶变换
fft_mean_coefficient_c = mean(abs(f_signal_c)); % 计算傅里叶变换系数的均值
wavelet_transform_c = dwt(signal_c, 'db4'); % 进行连续小波变换 确保您的 MATLAB 版本支持 cwt 函数
wavelet_absolute_mean_c = mean(abs(wavelet_transform_c(:))); % 计算小波变换的绝对均值
wavelet_standard_deviation_c = std(wavelet_transform_c(:)); % 计算小波变换的标准差
wavelet_variance_c = var(wavelet_transform_c(:)); % 计算小波变换的方差

clear,clc
load timeclass.mat
load timeArray.mat
load time_emr_c.mat
% 遍历元胞数组中的每个元素（但只关注第二列）
for i = 1:610932
    % 使用strcmp来比较第二列的字符串
    if strcmp(timeclass{i, 2}, 'A')
        numericArray(i) = 1;
    elseif strcmp(timeclass{i, 2}, 'B')
        numericArray(i) = 2;
    elseif strcmp(timeclass{i, 2}, 'C')
        numericArray(i) = 3;
    elseif strcmp(timeclass{i, 2}, 'D/E')
        numericArray(i) = 4;
    else
        % 如果存在其他字符串，可以添加错误处理或默认赋值
        warning('Unknown category: %s', cellArray{i, 2});
        % 例如，你可以设置一个默认值或忽略这个元素
        % numericArray(i) = NaN; % 或者其他默认值
    end
end
timeArray=timeArray';
```

```
numericArray=numericArray';
datenn = datenum(timeArray);
% total_emr=[datenn numericArray];
arry=[]
% a=[1;2;3;3;4;3;3]
% for i=1:7
%     if a(i)==3
%         num=i;
%         for j=num+1:7
%             if a(j)~=3
%                 label=j;
%                 break;
%             end
%         end
%         delt_time=datenn(label)-datenn(num) ;
%         arry(end+1)=delt_time;
%     end
% end
[r,c,v]=find(numericArray==3)
time_c=datetime()
time_c2=datetime()
count=0
num=1
label=false;
for i=1:length(r)-1

    if r(i)+2<r(i+1)
        delt_time=datenn(i)-datenn(num)
        arry(end+1)=delt_time;
        time_c(end+1)=timeArray(num)
        time_c2(end+1)=timeArray(i)
        num=num+count;
        label=true;
        count=0;

    end
    count=count+1
end
arry=arry';
delt=arry*24*60
```

随机森林

```
clc;clear all;close all;
%加载数据
```

```
f1 = importdata("D:\前兆特征.xls");
a=f1.textdata;
c1=f1.data;
Y = c1(:,1);
X = c1(:,1);
isCategorical = [zeros(15,1);ones(size(X,2)-15,1)]; % Categorical variable flag

leaf =5;
ntrees = 200;
fboot = 1;
disp('训练随机森林（TreeBagger）')
b = TreeBagger(ntrees, X,Y, 'Method','regression', 'oobvarimp','on', 'surrogate',
'on', 'minleaf',leaf,'FBoot',fboot);

%训练好的模型进行预测
disp('预测')
x = Y;
y1 = predict(b, X);

% 计算相关系数
x1=x(1:30000);
y11=y1(1:30000);
cct=corrcoef(x1,y11);
cct=cct(2,1);

% 创建散点图
disp('创建散点图')

% 绘制线
plot(x1,x1,'LineWidth',4);
hold on
scatter(x1,y11,'filled');
hold off
grid on
%创建 R 方图
set(gca,'FontSize',20)
xlabel('真实值','FontSize',20)
ylabel('预测值','FontSize',20)
title(['Training Dataset, R^2=' num2str(cct^2,2)],'FontSize',20)

drawnow
% Calculate the relative importance of the input variables
tic
disp('Sorting importance into descending order')
```

```
weights=b.OOBPermutedVarDeltaError;
[B,iranked] = sort(weights,'descend');
toc

disp(['Plotting a horizontal bar graph of sorted labeled weights.'])
figure
barh(weights(iranked),'g');
xlabel('Variable Importance','FontSize',20,'Interpreter','latex');
ylabel('Variable Rank','FontSize',20,'Interpreter','latex');
title(...
   ['Relative Importance of Inputs in estimating Redshift'],...
   'FontSize',10,'Interpreter','latex'...
   );
hold on
barh(weights(iranked(1:10)),'y');
barh(weights(iranked(1:5)),'r');

xt = get(gca,'XTick');
xt_spacing=unique(diff(xt));
xt_spacing=xt_spacing(1);
yt = get(gca,'YTick');
ylim([0.25 length(weights)+0.75]);
xl=xlim;
xlim([0 2.5*max(weights)]);

% 为每个栏添加文本标签
for ii=1:length(weights)
   text(...
      max([0 weights(iranked(ii))+0.05*max(weights)]),ii,...
      ['Column ' num2str(iranked(ii))],'Interpreter','latex','FontSize',11);
end
set(gca,'FontSize',16)
set(gca,'XTick',0:2*xt_spacing:1.1*max(xl));
set(gca,'YTick',yt);
set(gca,'TickDir','out');
set(gca, 'ydir', 'reverse' )
set(gca,'LineWidth',2);
drawnow

fn='RelativeImportanceInputs';
fnpng=[fn,'.png'];
print('-dpng',fnpng);

% 绘制权重等级变化
```

```
disp('绘制bag与生成树的关系')

figure
plot(b.oobError,'LineWidth',3);
xlabel('Number of Trees','FontSize',20)
ylabel('Out of Bag Error','FontSize',20)
title('Out of Bag Error','FontSize',20)
set(gca,'FontSize',16)
set(gca,'LineWidth',2);
grid on
drawnow
fn='EroorAsFunctionOfForestSize';
fnpng=[fn,'.png'];
print('-dpng',fnpng);

%模型评测
y2=y1(1:30000);
Y1=Y(1:30000);
Ape=abs(y2-Y1)./Y1;
Mape1=0;
[r,c]=size(Ape);
for i=1:r
   Mape1=Mape1+Ape(i,c);
end
disp('平均相对误差Mape: ')
Mape=Mape1/r
count1=sum(Ape(:)<=0.05)
disp('5%标准误差率')
Accuracy=count1/30000
disp('模型评测')
zzz=0.2*(1-Mape)+0.8*Accuracy
```